

Leveraging Large Language Models to Enhance Supervised Classification of Political Incivility on Social Media

Laia Castro¹ · Martín García¹ · Alejandro de la Fuente² · Paula Szewach² · Itzá Camacho¹ · Alex Casadevall¹ · Yuan Zhang³ · Michael Amsler³ · Frank Esser³

Universitat de Barcelona¹ · Barcelona Supercomputing Center² · Universidad de Zúrich³



UNIVERSITAT^{DE}
BARCELONA

El problema

- La incivildad política en redes sociales está muy extendida, pero medirla rigurosamente a gran escala sigue siendo un reto.
- Los enfoques existentes suelen centrarse en definiciones estrechas, como toxicidad o faltas de respeto, que no capturan todo el espectro del discurso incivil.
- Los modelos supervisados necesitan muchos datos de entrenamiento codificados manualmente.
- La anotación humana es gold-standard, pero es cara, lenta y difícil de escalar.
- ¿Pueden los LLMs generar anotaciones comparables a las de codificadores humanos?
 - ¿Operacionalizan bien definiciones matizadas y teóricamente fundamentadas de incivildad política?
 - ¿Pueden los datos etiquetados por LLMs entrenar clasificadores con rendimiento comparable al de los datos humanos?



Qué hacemos I

- **Comparamos anotaciones humanas y anotaciones generadas por LLMs como datos de entrenamiento para un clasificador de incivilidad política.**
- Evaluamos nueve LLMs de código abierto frente a la anotación humana en nueve dimensiones de incivilidad política.
- Entrenamos clasificadores basados en SentenceTransformers usando tanto datos etiquetados por humanos como datos generados por LLMs.
- Evaluamos si la supervisión débil basada en LLMs puede alcanzar un rendimiento comparable o superior, permitiendo al mismo tiempo una clasificación a gran escala más eficiente en costes.



Qué hacemos II

- **5 dimensiones de incivilidad política que capturan sus implicaciones democráticas más amplias**
- Analizamos casi 4 millones de publicaciones políticas
 - A lo largo de 10 años
- **En 4 plataformas de redes sociales diferentes**
- **Abarcando 3 eventos políticamente relevantes**



UNIVERSITAT_{DE}
BARCELONA

Incivilidad: dimensiones principales



UNIVERSITAT DE
BARCELONA

1. Faltas de respeto

- Insultos o descalificaciones (p. ej., 'traidor', 'idiota'); lenguaje ofensivo o peyorativo; blasfemias; afirmaciones hiperbólicas (Chen et al., 2020; Papacharissi, 2004; Theocharis et al., 2016); gritos e interrupciones (Mutz, 2015).

2. Estereotipos o discurso de odio

- Hostilidad o discriminación basada en la identidad social o en estereotipos; difusión de noticias falsas para deshumanizar o discriminar a grupos definidos por su identidad.

3. Amenazas a las libertades democráticas

- Socavar derechos o valores democráticos; llamar a restringir libertades; deslegitimar elecciones o instituciones; promover la autocracia o usar lemas patrióticos de carácter autoritario.

Incivilidad: otras dimensiones



UNIVERSITAT DE
BARCELONA

4. Simplicidad argumentativa

- Baja calidad deliberativa en términos de justificación (Jaidka et al., 2019; Wessler & Rinke, 2014). Incluye comunicación populista y desinformación.

5. Exclusión

- Mensajes que desincentivan la participación o muestran insensibilidad hacia grupos o individuos concretos (Jaidka et al., 2019).

6. Sarcasmo, cinismo y burla

- Expresiones irónicas o cínicas que denigran a individuos o grupos, o que los atacan indirectamente de forma sutil.

7. Daño físico / retórica política violenta

- Mensajes que amenazan directa o indirectamente con causar daño físico a actores políticos o incitan a otros a infligirlo.

8. Negatividad

- Tono o atmósfera general pesimista, fatalista o derrotista (Fridkin & Kenney, 2008; Pennebaker et al., 2015).

9. Ataques personales

- Ataques dirigidos contra actores políticos como individuos, centrados en su físico, carácter personal, o integridad.

Datos

Table 1. Dataset composition

ID	Source	N	Period or temporal criterion	Filtering/context
01	Facebook	720,044	Conversations around the 2023 Spanish general election	Spanish-language posts/comments; thread reconstruction with up to three previous comments in context .
02	Twitter/X DANA	41,026	November 2024 Valencia DANA; dataset obtained in March 2025	Political subset; Spanish-language tweets; context when a thread or conversational reference was available.
03	Telegram	658,623	Influencer channels during the 2023 Spanish general election	Spanish-language posts and replies; conversational context when available.
04	YouTube	1,010,428	Comments during the 2023 Spanish election period	Spanish-language comments; up to three previous comments as context when possible.
05	Twitter/X LGBT	694,606	Tweets about the LGBT community on Pride Day; dataset obtained in 2025	Socially contentious debate; language-filtered to Spanish.
06	Twitter/X general Spanish	657,117	General Spanish-language tweets collected on Pride Day; dataset obtained in April 2025	Broader-distribution source including cases that are not necessarily uncivil or explicitly political.
Total N (posts and comments)		3,781,844		



Análisis



UNIVERSITAT DE
BARCELONA




Figure 1. Workflow of data annotation and classification.

Análisis II

Las publicaciones se clasifican usando nueve LLMs de código abierto, evaluados frente a un gold standard codificado por humanos:

- **Gemma-4-26B-A4B,**
 - **Gemma-3-27B-Instruct,**
 - **Qwen2.5-32B-Instruct,**
 - **Qwen3-32B,**
 - **QwQ-32B,**
 - **DeepSeek-R1-Distill-Qwen-7B/32B,**
 - **Llama-3.1-8B-Instruct y**
 - **Mistral-Small-24B-Instruct-2501**
- **Clasificadores: BERT multilingüe fine-tuned y nueve clasificadores basados en SentenceTransformers (EmbeddingGemma + LR), usando tanto datos etiquetados por humanos como datos generados por LLMs.**
 - Evaluamos si la supervisión débil basada en LLMs puede alcanzar un rendimiento comparable o superior, permitiendo una clasificación a gran escala más eficiente en costes.



Resultados

Table 2. Majority-vote positives and agreement among three coders by dimension in the gold-annotated dataset (N=3000).

Dimension	N	MV Agreement positives	Balanced Agr.	Fleiss κ	Kripp. α	Gwet AC2	
Impoliteness	3000	1070	68.03	76.83	0.535	0.535	0.607
Negativity	3000	140	85.93	64.78	0.262	0.262	0.893
Sarcasm, Cynicism, Mockery	3000	260	83.87	72.19	0.428	0.428	0.868
Hate Speech and Stereotyping	3000	379	84.33	78.43	0.564	0.564	0.863
Exclusion	3000	85	92.70	68.57	0.359	0.360	0.947
Attack Against Political Actors	3000	542	81.07	79.40	0.586	0.586	0.818
Threats to Democratic Freedoms	3000	199	93.90	85.00	0.700	0.700	0.953
Physical Harm/Violent Political Rhetoric	3000	123	93.67	78.48	0.551	0.551	0.953
Simplistic Arguments in Policy Discussions	3000	291	81.37	71.92	0.404	0.404	0.843



Resultados

Table 3. LLM performance under the original nine-dimensional prompt, before prompt optimization.

Rank	Model	Macro-F1 9D	Micro-F1 9D	Exact 9D
1	Gemma-4-26B-A4B-It	0.590	0.624	0.464
2	Gemma-3-27B-It	0.523	0.583	0.453
3	Mistral-Small-24B-Instruct-2501	0.511	0.598	0.406
4	Qwen3-32B	0.507	0.547	0.470
5	Qwen2.5-32B-Instruct	0.503	0.532	0.395
6	QwQ-32B	0.473	0.502	0.422
7	Llama-3.1-8B-Instruct	0.411	0.434	0.191
8	DeepSeek-R1-Distill-Qwen-32B	0.369	0.435	0.492
9	Llama-3.2-3B-Instruct	0.261	0.291	0.165
10	GPT-OSS-20B	0.043	0.054	0.447
11	DeepSeek-R1-Distill-Qwen-7B	0.004	0.003	0.447




Pipeline de optimización del prompt



UNIVERSITAT DE
BARCELONA

Prompt optimization: what was improved

A diagnostic process that turned the codebook prompt into a controlled silver-annotation pipeline.



What changed substantively

Clearer scope

Removed less stable dimensions and focused the automated pipeline on the five core labels.

Operational coding rules

Definitions became decision rules: when to mark 1, when to mark 0, and what to exclude.

FN-aware adjustment

Review of missed positives prevented the prompt from becoming too conservative on rare cases.

Stored audit trail

False positives, false negatives, candidate prompts, and round metrics were kept for justification.

Resultados

Table 4. Final by-dimension performance of the selected prompt-optimization strategy with Gemma-4-26B-A4B-It on the 3,000-observation human gold set

Dimension	Selected prompt strategy	Precision	Recall	Accuracy	Macro F1	Positive F1
Impoliteness	Joint multilabel prompt	0.784	0.754	0.838	0.822	0.769
Hate Speech and Stereotyping	Joint multilabel prompt	0.592	0.723	0.902	0.797	0.651
Attack Against Political Actors	Dimension-specific strict prompt	0.662	0.720	0.883	0.809	0.690
Threats to Democratic Freedoms	Dimension-specific strict prompt	0.795	0.683	0.967	0.859	0.735
Physical Harm/Violent Political Rhetoric	Dimension-specific strict prompt	0.625	0.569	0.968	0.790	0.596

Positive F1 refers to the F1 score for the positive class of each binary incivility dimension. The selected strategy combines a joint multilabel prompt for dimensions where it performed best with dimension-specific strict prompts for dimensions where they improved positive-class F1.



Resultados

Table 5. Aggregate performance before and after prompt optimization.

Annotation pipeline	Dimensions	Macro-F1	Micro-F1
Original prompt, before optimization	9	0.590	0.624
Final optimized pipeline	5	0.688	0.717

Note: The comparison contrasts the original nine-dimensional prompt with the final five-dimensional optimized pipeline.



Resultados

Table 6. Positive-class F1 by dimension for lightweight supervised classifiers on the manually labeled test set (N=450)


Classifier	Training data	Impoliteness	Hate	Attack	Democracy	Physical Harm
EmbeddingGemma + LR	Human-only	0.662	0.509	0.630	0.537	0.292
EmbeddingGemma + LR	Human-only cross-validated downsampling	0.644	0.494	0.617	0.537	0.333
BERT	Human + 100k silver	0.694	0.583	0.610	0.500	0.222
EmbeddingGemma + LR	Weighted human + 100k silver	0.659	0.473	0.660	0.571	0.233
EmbeddingGemma + LR	Weighted human + 50k silver	0.684	0.503	0.651	0.511	0.222
BERT	Human + 50k silver	0.665	0.588	0.655	0.579	0.077
EmbeddingGemma + LR	Human + 50k silver	0.687	0.409	0.634	0.561	0.192
EmbeddingGemma + LR	Human + 100k silver	0.665	0.473	0.625	0.571	0.146
EmbeddingGemma + LR	Silver-only 100k	0.656	0.409	0.624	0.512	0.194
EmbeddingGemma + LR	Silver-only 50k	0.647	0.426	0.637	0.432	0.177
BERT	Silver-only 100k	0.664	0.544	0.575	0.400	0.083
BERT	Silver-only 50k	0.640	0.496	0.599	0.429	0.000
BERT	Human-only	0.554	0.275	0.518	0.471	0.000



Resultados



UNIVERSITAT DE
BARCELONA



(a) Including Physical Harm

Figure 2. Model comparison by macro-F1 on 450-text human test set, with and without Physical Harm.

Resultados



UNIVERSITAT DE
BARCELONA




Figure 2. Model comparison by macro-F1 on 450-text human test set, with and without Physical Harm.

Aportes



UNIVERSITAT_{DE}
BARCELONA

Cuatro contribuciones principales:

- Los prompts diseñados para LLMs pueden operacionalizar definiciones teóricas matizadas de incivilidad política y superar clasificadores genéricos de toxicidad o descortesía.
- Ampliamos el alcance empírico a interacciones ciudadanas espontáneas en distintas plataformas, contextos y periodos temporales.
- **Proponemos un pipeline escalable en el que los LLMs generan datos de entrenamiento para clasificadores posteriores, con resultados comparables a enfoques manuales y útiles para análisis a gran escala.**
- Ponemos a disposición de la comunidad científica los clasificadores fine-tuned, el código y los datos subyacentes.
- En conjunto, los LLMs ofrecen una vía práctica para entrenar clasificadores que combina rigor teórico, escalabilidad empírica y eficiencia computacional.


Table 7. Aggregate performance of supervised classifiers on the manually labeled test set (N=450), excluding Physical Harm.

Classifier	Training data	Macro F1	Micro F1	Precision	Recall	Accuracy	Macro κ	Pooled κ
BERT	Human + 50k silver	0.622	0.643	0.666	0.622	0.872	0.537	0.565
BERT	Human + 100k silver	0.597	0.639	0.721	0.574	0.880	0.521	0.568
EmbeddingGemma + LR	Weighted + 100k silver	0.591	0.619	0.526	0.751	0.829	0.470	0.513
EmbeddingGemma + LR	Weighted + 50k silver	0.587	0.623	0.546	0.724	0.838	0.480	0.522
EmbeddingGemma + LR	Human-only	0.584	0.623	0.557	0.706	0.842	0.473	0.524
EmbeddingGemma + LR	Human + 100k silver	0.583	0.606	0.588	0.625	0.849	0.485	0.513
EmbeddingGemma + LR	Human + 50k silver	0.573	0.614	0.563	0.676	0.843	0.466	0.516
EmbeddingGemma + LR	Human-only cross-validated downsampling	0.573	0.599	0.530	0.688	0.829	0.457	0.493
EmbeddingGemma + LR	Silver-only 100k	0.550	0.589	0.584	0.595	0.847	0.450	0.495
BERT	Silver-only 100k	0.546	0.600	0.678	0.538	0.867	0.462	0.521
BERT	Silver-only 50k	0.541	0.587	0.646	0.538	0.860	0.453	0.503
EmbeddingGemma + LR	Silver-only 50k	0.536	0.585	0.588	0.583	0.847	0.436	0.492
BERT	Human-only	0.454	0.498	0.654	0.402	0.850	0.367	0.416

Metrics are computed over four dimensions: Impoliteness, Hate Speech and Stereotyping, Attack Against Political Actors, and Threats to Democratic Freedoms. Physical Harm/Violent Political Rhetoric is excluded. Exact match is not reported because it requires instance-level predictions for the reduced four-label set.


Table A1. Inter-coder agreement by dimension in the first annotation round (N=2000).

Dimension	N	MV positives	Agreement	Balanced Agr.	Fleiss kappa	Kripp. alpha	Gwet AC2
Impoliteness	2000	766	68.10	77.40	0.547	0.547	0.599
Negativity	2000	99	84.70	66.36	0.238	0.238	0.882
Sarcasm, Cynicism, Mockery	2000	191	81.80	71.49	0.412	0.412	0.847
Hate Speech and Stereotyping	2000	246	83.85	77.57	0.543	0.543	0.859
Exclusion	2000	38	94.35	67.57	0.327	0.327	0.960
Attack Against Political Actors	2000	373	81.70	80.48	0.605	0.605	0.823
Threats to Democratic Freedoms	2000	137	94.70	86.99	0.738	0.738	0.959
Physical Harm/Violent Political Rhetoric	2000	66	94.55	79.38	0.540	0.540	0.961
Simplistic Arguments in Policy Discussions	2000	215	79.75	72.84	0.406	0.406	0.825

Agreement and balanced agreement are reported as percentages. MV positives are majority-vote positive labels.


Table A2. Intercode agreement by dimension in the second annotation round (N=1000).

Dimension	N	MV positives	Agreement	Balanced Agr.	Fleiss kappa	Kripp. alpha	Gwet AC2
Impoliteness	1000	304	67.90	75.98	0.504	0.504	0.624
Negativity	1000	41	88.40	66.67	0.318	0.318	0.913
Sarcasm, Cynicism, Mockery	1000	69	88.00	73.89	0.467	0.467	0.906
Hate Speech and Stereotyping	1000	133	85.30	80.20	0.602	0.603	0.870
Exclusion	1000	47	89.40	70.21	0.383	0.383	0.920
Attack Against Political Actors	1000	169	79.80	77.37	0.547	0.547	0.808
Threats to Democratic Freedoms	1000	62	92.30	81.62	0.624	0.624	0.941
Physical Harm/Violent Political Rhetoric	1000	57	91.90	78.36	0.562	0.562	0.938
Simplistic Arguments in Policy Discussions	1000	76	84.60	70.09	0.393	0.393	0.876

Agreement and balanced agreement are reported as percentages. MV positives are majority-vote positive labels.